

ÁREA TEMÁTICA: INNOVACIÓN Y GESTIÓN DEL CONOCIMIENTO

TÍTULO DE LA PONENCIA: DEEP LEARNING. UNA REVISIÓN.

AUTORES: Reinier Hernández Ávila (rhernandez@uho.edu.cu)

Teléfono (+53 54671936)

Dirección: Calle 9, % Calle 22 y Calle Final, #2ª, Hilda Torres, Holguín, Holguín, Cuba, CP: 80100

Ing. Luis David Gonzalez Oroscó (ldgonzalez@uho.edu.cu)

Teléfono (+53 54091405)

Ing. Luis Miguel Sánchez Velázquez (lsanchezv@uho.edu.cu)

Teléfono (+53 54535349)

Msc. Eduardo Pérez Perdomo (eperezp@uho.edu.cu)

Teléfono (+53 58395649)

Msc. María Hidalgo Oberto (mariaho@uho.edu.cu)

Teléfono: (-)

Institución: Universidad de Holguín, Cuba.

RESUMEN

Actualmente el mundo se adentra en una era de un gran cúmulo de datos (conocido como *Big Data*) donde muchos problemas de tomas de decisión son resueltos mejor por máquinas que por humanos, en términos de exactitud y escalabilidad. El aprendizaje profundo es una rama del Aprendizaje automático que utiliza una gran cantidad de metadatos para enseñar a las computadoras cómo hacer las cosas que anteriormente solo los humanos éramos capaces de hacer. Permite operar modelos computacionales que están compuestos de múltiples capas de procesamiento, aprender representaciones de datos con múltiples niveles de abstracción, disminuir algunos costos de procesamiento. Se muestran las diferentes arquitecturas que cumplen con dicho concepto como estas se relacionan con las redes neuronales artificiales (RNA), tanto por su arquitectura, como por su tipo de entrenamiento. Realizando de esta forma, una taxonomía que explica o clasifica algunas de las redes que conforman el *Deep Learning*.

PALABRAS CLAVE: Aprendizaje profundo, Redes neuronales, *Big Data*, Aprendizaje automático

ABSTRACT

Currently the world is entering an era of a large data cluster (known as Big Data) where many decision-making problems are solved better by machines than by humans, in terms of accuracy and scalability. Deep learning is a branch of Machine Learning that uses a lot of metadata to teach computers how to do things that only humans were previously able to do. It allows operating computational models that are composed of multiple layers of processing, learn data representations with multiple levels of abstraction, decrease some processing costs. The different architectures that comply with this concept are shown as they relate to artificial neural networks (RNA), both for their architecture and for their type of training. Doing this way, a taxonomy that explains or classifies some of the networks that make up the Deep Learning.

KEYWORDS: Deep Learning, Neural Network, Big Data, Machine Learning

1. INTRODUCCIÓN

En la actualidad, los datos que se crean y se almacenan crecen de manera exponencial. Dicha acumulación de datos se debe al crecimiento continuo, de forma masiva a partir del 2004, por parte de los usuarios de las distintas redes sociales como Facebook, Twitter, Instagram, Google Plus y otros; así como foros, blogs, sitios multimedia, juegos *online*, etc. También el crecimiento de las tecnologías móviles, permitiéndoles a estos conectarse a internet como teléfonos inteligentes, *laptops*, computadoras, *tablets*, entre otros. Este fenómeno es conocido como *Big Data* haciendo referencia a una gran cantidad de datos que supera la capacidad de *software* regular para ser capturados, gestionados y procesados en un tiempo razonable.(Madden 2012)

En los años 80 se hizo de forma práctica la toma de decisión con el uso de grandes cúmulos de datos. Actualmente el mundo se entra en una era de *Big Data* donde muchos problemas de toma de decisión son resueltos mejor por máquinas que por humanos, en términos de exactitud y escalabilidad.

El aprendizaje automático (*ML*, por sus siglas en inglés, *Machine Learning*) es la rama de la inteligencia artificial (*AI*, por sus siglas en inglés, *Artificial Intelligence*) encargada del desarrollo de técnicas, algoritmos, y programas que doten a las computadoras la capacidad de aprender. A grandes rasgos se puede decir que una máquina aprende cada vez que cambia su estructura, programa o datos, basados en una entrada o como respuesta de información externa, de tal manera que se esperen mejor rendimiento en el futuro (Nilsson 1996).

Dicha área de investigación tiene un amplio impacto ya que es utilizada en la clasificación de texto y multimedia, el procesamiento del lenguaje natural, predicción de enfermedades, descubrimiento conocimiento valioso de grandes bases de datos comerciales (Mitchell 1997), por solo mencionar algunos ejemplos. En la literatura se definen dos grandes grupos, el de aprendizaje supervisado (*SL*, por sus siglas en inglés, *Supervised Learning*) y aprendizaje no supervisado (*UL*, por sus siglas en inglés, *Unsupervised Learning*). Dentro del primero se encuentra como tareas principales la clasificación, la regresión; en el segundo está el agrupamiento, también conocido en la literatura como *clustering* (Rodríguez Hernández 2011, Perdomo 2013).

Dentro del área de *ML* existen múltiples *frameworks* como apoyo al proceso de experimentación y desarrollo de nuevos algoritmos. De los más populares se puede mencionar Weka y Keel. Weka es uno de los frameworks más populares y difundidos de los *ML*. Keel posee algoritmos de *SL*, *UL* y además soporta muchas de las técnicas de pre procesamiento de datos. En el área de *AI* se han desarrollado algunas bibliotecas de clase aplicada a un dominio en específico como *Active Multi-Instance Library*, *Active Experimenter* y *Minorthird*.

A partir del 2006, Geoffrey Hinton, acuña el término aprendizaje profundo (*DL*, por sus siglas en inglés, *Deep Learning*) para explicar nuevas arquitecturas de redes neuronales (*NN*, por sus siglas en inglés, *Neural Net*) profundas que son capaces de aprender mucho mejor que los modelos planos. *DL* es una clase de técnicas de aprendizaje automático que explotan muchas capas de procesamiento no lineal para la extracción y transformación de funciones supervisadas y no supervisadas, y para el análisis y la clasificación de patrones (Deng and Yu 2014). Un conjunto de datos u observación puede ser representada de muchas formas, pero algunas representaciones hacen más fácil aprender tareas de interés sobre la base de ejemplos, y la investigación en esta área intenta definir qué representaciones son mejores y cómo crear modelos para aprender estas representaciones. El siglo XXI se ha convertido en la edad de oro de para la *AI*; esto es debido, en gran parte, a una mayor capacidad de cómputo, y al uso de GPUs para acelerar el entrenamiento de estos sistemas con grandes cantidades de datos, junto a implementaciones más eficientes y en algunas mejoras puntuales. Probablemente, el mayor hito al respecto fue el resultado de unos investigadores de la Universidad de Toronto que en

2012 revolucionaron los *benchmarks* de la mayor competición mundial de reconocimiento de imágenes y, en 2013, fueron contratados por Google. Actualmente existen numerosos *frameworks* que tienen implementados *DL* como TensorFlow, Keras, DL4J, entre otros.

2. ANTECEDENTES DE *DEEP LEARNING*

Las investigaciones cada vez más exhaustivas acerca del funcionamiento del cerebro y del paradigma de la inteligencia humana han permitido que la *AI* evolucione, por medio de las redes neuronales artificiales (RNA, por sus siglas en español), para elaborar un sistema semejante capaz de lograr semejante hazaña. Desde 1934, en los primeros intentos por elaborar una RNA (Caicedo Bravo and López Sotelo 2017), se han construido modelos más sofisticados y robustos, con un nivel de acercamiento cada vez mayor al comportamiento del cerebro, hasta llegar al punto del aprendizaje profundo o *DL*. A principios de los años 80 se desarrolló un concepto que, más tarde Geoffrey Hinton acuñaría el término de *DL* en el 2006, que ayudó a lanzar una revolución ambiciosa al explorar las RNA, en la universidad de Cambridge y la Universidad de Edimburgo, la cual consistía en imitar el cerebro para crear una forma más pura de la *AI* (Hernandez 2014). Sin embargo, en esa época las computadoras no tenían la capacidad computacional requerida para procesar enormes colecciones de datos que requerían las RNA, por lo que su éxito fue limitado; con lo que la comunidad de *AI* les dio la espalda.

En 1991, el investigador Jürgen Schmidhuber elabora una red de cientos de operadores lineales o capas de neuronas, el cual, mediante el uso de un “preentrenamiento no supervisado”, entrena una red neuronal recurrente (*RNN*, por sus siglas en inglés, *Recurrent Neural Net*); generando una memoria temporal jerárquica, que comprime datos. Esta, según su mismo autor, es una de las primeras técnicas de *DL* en superar el problema asociado con el colapso parcial de una pérdida de memoria jerárquica, debido a la compresión de los niveles más altos hacia los bajos de las capas de “preentrenamiento”.

En 2004, con una pequeña cantidad de fondos otorgada por el *Canadian Institute for Advanced Research (CIFAR)* y el apoyo de Yann LeCun y Yoshua Bengio, Hinton fundó el programa *Neural Computation and Adaptive Perception*, un grupo selecto de científicos de la computación, biólogos, ingenieros electrónicos, neurocientíficos, físicos y psicólogos. Esto permitió la búsqueda de pensadores o investigadores de talla mundial con los cuales, además de permitir el avance del concepto de *DL*, se dedicarían a la creación de sistemas informáticos que imiten la inteligencia ecológica.

Con la creación y publicación de artículos y conferencias sobre esta tecnología, en 2006, se le acuñó el término de *Deep Learning* en el contexto del “preentrenamiento no supervisado” para las redes *feedforward* que tenían una jerarquía de memoria.

Actualmente la *AI* está de moda, pues parte de los integrantes de Jürgen son contratados por diferentes entidades para el desarrollo de esta novedosa tecnología y por parte del grupo de Hinton, el mismo trabaja a tiempo parcial en Google y LeCun está trabajando para Facebook, ambos desde el 2013. Estas novedosas técnicas también están siendo aplicadas en otras grandes empresas como son el caso de Microsoft, IBM, Baidu, etc.

3. APLICACIONES PRACTICAS DE *DEEP LEARNING*

Entre los principales usos de *DL* en la actualidad se encuentra identificar marcas y logotipos de empresas en fotos publicadas en las redes sociales, monitorización en tiempo real de reacciones en

canales *online* durante el lanzamiento de productos, orientación de anuncios y predicción de preferencias de los clientes, identificación y seguimiento de los niveles de confianza de los clientes, sus opiniones y actitud de diferentes canales online y servicios de soporte automatizado al cliente, identificación de clientes potenciales, detección de fraudes, recomendación a clientes, gestión de relaciones con los clientes, etc.; mejor comprensión de enfermedades y terapias genéticas, análisis de imágenes médicas, como radiografías y resonancia magnéticas, aumentando la precisión de diagnóstico, en un menor tiempo y con un menor coste que los métodos tradicionales, exploración de la posibilidad de reutilización de fármacos ya conocidos y probados para su uso contra nuevas enfermedades, identificación en textos de sentimientos positivos y negativos, temas, palabras claves; localización de caras e identificación de emociones faciales; reconocimiento de voz, clasificación de videos y mucho más.

4. CONCLUSIONES

Con el actual desarrollo de la internet de las cosas (*IoT*, por sus siglas en inglés, *Internet of Things*), que no es más que la interconexión digital de los objetos cotidianos a internet, el fenómeno *Big Data* seguirá creciendo exponencialmente, contribuyendo aún más con datos de entrenamiento para las *NN*. Otro dato importante que impulsa el actual auge de *DL* es la revolución tecnológica de este siglo. La producción de GPUs cada vez más potentes y la programación distribuida son catalizadores del uso de *AI* para la vida cotidiana donde existen pentabytes de información y la necesidad de tomar decisiones en escalas temporales del orden de milisegundos. La búsqueda, análisis de satisfacción del usuario, análisis de marketing, comandos de voz, etc.; son tareas que tienen algo en común, todas requieren percibir lo que pasa en el entorno mediante la adquisición de datos y todas requieren realizar un procesamiento de la información para interpretar la realidad y extraer el significado, de forma que posteriormente se pueda razonar sobre ese significado y tomar decisiones para realizar acciones adaptativas. Precisamente por esto se produce una fiebre de los datos en todas las industrias. Al igual que en la fiebre del oro, existe un gran valor oculto en los millones y millones de toneladas de datos que una organización puede recabar. La inteligencia se produce cada vez de forma más distribuida, para dar solución a nuestros problemas ahora que podemos preguntar directamente a nuestras máquinas y esperar una respuesta cada vez más inteligente. La gran responsabilidad que nos queda a los humanos es de hacer las preguntas adecuadas.

5. BIBLIOGRAFÍA

Caicedo Bravo, E. F. and J. A. López Sotelo (2017). Una aproximación práctica a las redes neuronales artificiales [recurso electrónico].

Deng, L. and D. Yu (2014). "Deep learning: methods and applications." *Foundations and Trends® in Signal Processing* 7(3–4): 197-387.

Hernandez, D. (2014). "Meet the Man Google Hired to Make AI a Reality." *Wired Magazine*.

Madden, S. (2012). "From databases to big data." *IEEE Internet Computing* 16(3): 4-6.

Mitchell, T. M. (1997). "Machine learning. 1997." Burr Ridge, IL: McGraw Hill 45(37): 870-877.

Nilsson, N. J. (1996). "Introduction to machine learning. An early draft of a proposed textbook."

Perdomo, E. P. (2013). "PROPUESTA DE UN FRAMEWORK PARA APRENDIZAJE ACTIVO."

Rodríguez Hernández, M. d. C. (2011). Diseño de un modelo de realimentación por relevancia basado en aprendizaje activo para el entorno periodístico digital cubano.

